

数据源清单

实测日期 2026-09-02 · 42 条,通 41 条 · 探测机器:MacBook(Clash TUN 开着) 这份清单的表格不是手写的,是每次真调一次生成的。 手写的数据源清单必然过期 —— 2026-09-01 就发现三条记成「拿不到」的 (Motley Fool 电话会纪要 / roic.ai / stockanalysis.com)其实一直是通的, 而这三条正好卡着「云厂下期 capex 指引」这个最领先的指标。

怎么更新这份清单

```
export SEC_UA='astock-lab research <你的邮箱>'          # SEC 强制要求,缺了一律 403
$VENV/bin/python tools/probe_all_sources.py \
    --json /tmp/sources.json --markdown /tmp/sources.md
# 把 /tmp/sources.md 的内容替换掉下面「实测清单」那一节
```

退出码:0 = 必需源全通;1 = 有必需源不通。只测一组:--group 领先指标。

加新数据源的规矩:先在 tools/probe_all_sources.py 的 build() 里加一条探针

(带 URL、用途、领先/滞后属性),跑通了再写进取数脚本。顺序反了就会出现「脚本里写着能拿,实际早就拿不到」。

一、先看覆盖度:按分析顺序倒推

分析一只股票的顺序是 领先 → 同步 → 滞后。绝大多数股票数据都是后视镜,真正领先的只有下面这几类。清单的价值不在条数,在领先那一栏够不够。

层	需要回答	我们有的	缺口
① 需求源头(最领先)	客户下季度还买不买	云厂 capex 指引(电话会)· SEC 已发生 capex · 海外同业电话会 · 油价 · 钻机数 · 全球油气 capex	面板厂 capex 要自己从现金流量表算(能拿,没接)
② 公司自己的前瞻	公司/机构怎么说下期	业绩预告 · 业绩快报 · 券商一致预期 · 评级变动方向 · 机构调研家数	外资行评级/目标价拿不到(巨潮只覆盖境内);公司季度指引散在公告与纪要里,没结构化
③ 事件	有没有刚发生的变化	公告(中标/合同/订单)· 龙虎榜 · 限售解禁	公告只取到列表,正文关键词识别没做
④ 现在(同步)	当下什么价、谁在买	实时行情 · 五档逐笔 · 融资余额 · 汇率 · 中美国债	个股资金流(push2his 不稳);北向个股方向永久没有
⑤ 后视镜(滞后)	上一季兑现没有	三表 + 杜邦 + 偿债 + 营运 + 现金流 · 股东户数 · 估值历史分位 · 全市场基准率	财报重述追踪要付费;审计意见要付费

一之二、抓下来放哪:落盘结构

```
data/raw/
├─ quotes/ financials/ forecast/ consensus/ ratings/
├─ surveys/ announcements/ research/ chips/      ← A 股,<code>/<date>.json
├─ overseas/    <ticker>/<date>.json             ← 海外上下游 21 只
├─ transcripts/ <会议>/<date>.txt                 ← 电话会纪要正文
├─ macro/      <date>-<项>.json
└─ meta/      <date>.json                        ← 本次抓取的健康汇总
```

每个文件是信封不是裸数据:

```
{"source":"baostock query_forecast_report","url":"...","fetched_at":"2026-09-01T23:42:11",
 "params":{"...},"ok":true,"rows":4,"error":null,"data":[...]}
```

时效、出处、成败因此是免费得到的。抓失败的条目留在盘上标 `ok:false` ——

静默丢弃会让读的人以为这类数据根本不存在,而「今天没抓到」和「不存在」

对决策的含义完全相反。

三条命令:

```
tools/probe_all_sources.py --json /tmp/s.json --markdown /tmp/s.md # 先探
tools/fetch_all.py --codes 300502,300308 --peers --macro # 再抓
tools/data_digest.py --code 300502 --overseas --pdf # 出文档
```

data_digest.py 出的是给人读的数据源明细(MD + PDF):一只股票当前手上到底有哪些数据、来自哪个源、抓于何时、内容是什么、还缺什么,按「领先→同步→滞后」组织,可以直接发出去。

二、实测清单

1 行情与技术位

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
新浪实时快照 ★	同步	五档/最新价/成交量	tools/astock.py	✅ 通 · 有报价
腾讯实时/逐笔 ★	同步	快照 + 逐笔明细	tools/astock.py	✅ 通 · 有报价
腾讯日线(前复权)	滞后	OHLCV 历史	tools/astock.py	✅ 通 · 60 根
baostock 日线+估值 ★	滞后	OHLCV + peTTM/pbMRQ/psTTM(历史分位的唯一来源)	baostock query_history_k_data_plus	✅ 通 · 22 根,末 peTTM=42.810370
新浪美股日线	领先	海外同业股价(市场先反应)	akshare stock_us_daily	✅ 通 · 9387 行 × 6 列

2 A股财务(baostock)

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
盈利能力 query_profit_data	滞后	ROE/净利率/毛利率/EPS	baostock query_profit_data	✅ 通 · 1 行 ['sz.300502', '2026-08-25', '2026-06-30', '0.356666']
成长能力 query_growth_data	滞后	营收/净利/总资产同比	baostock query_growth_data	✅ 通 · 1 行 ['sz.300502', '2026-08-25', '2026-06-30', '1.008975']
偿债能力 query_balance_data	滞后	流动比/速动比/资产负债率/权益乘数/总负债同比	baostock query_balance_data	✅ 通 · 1 行 ['sz.300502', '2026-08-25', '2026-06-30', '2.603456']
现金流 query_cash_flow_data	滞后	经营现金流/营收、每股现金流	baostock query_cash_flow_data	✅ 通 · 1 行 ['sz.300502', '2026-08-25', '2026-06-30', '0.772544']

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
杜邦分解 query_dupont_data	滞后	ROE = 净利率 × 周转率 × 权益乘数	baostock query_dupont_data	✅ 通 · 1 行 ['sz.300502', '2026-08-25', '2026-06-30', '0.356666']
营运能力 query_operation_data	滞后	应收周转率/存货周转率	baostock query_operation_data	✅ 通 · 1 行 ['sz.300502', '2026-08-25', '2026-06-30', '3.483672']
业绩预告 query_forecast_report	领先	净利预告区间,比正式财报早 2-6 周。无预告本身也是信息(变动在 ±50% 内)	baostock query_forecast_report	✅ 通 · 4 条,最近 2026-07-20 预增
业绩快报 query_performance_express_report	领先	正式财报前的营收/净利快报	baostock query_performance_express_report	✅ 通 · 2 条
全市场状态 query_all_stock	元数据	tradeStatus 1=正常 0=停牌;配 query_stock_basic 的名称含 ST 判风险警示。只能当验证标签,不能当打分输入(事后贴标 = 马后炮 + 回测前视)	baostock query_all_stock	✅ 通 · 7369 只,其中停牌 7
复权因子 query_adjust_factor	元数据	回测可复现的前提 —— 目标价/成本价与日线必须在同一复权基准上。2026-09-01 踩过:拿未复权目标价比未复权日线,基准混了(送转系数 1.40)	baostock query_adjust_factor	✅ 通 · 3 次除权除息
行业分类 query_stock_industry	元数据	行业中性化 / 同业对照的分组依据	baostock query_stock_industry	✅ 通 · C39计算机、通信和其他电子设备制造业
交易日历 query_trade_dates	元数据	所有定时任务的前置闸:非交易日直接跳过	baostock query_trade_dates	✅ 通 · 32 天,其中交易日 22

3 财务与筹码(东财)

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
datacenter-web 主机	一	报表类数据总入口	requests	✅ 通 · 有数据
机构调研 RPT_ORG_SURVEYNEW	领先	接待机构数 / 会议形式 / 时间 / 接待人。异常时点(周末夜间)+ 家数 骤变是信号	datacenter-web reportName=RPT_ORG_SURVEYNEW	✅ 通 · 共 819 次,最近接待 145 家
股东户数	滞后	户数 / 上期户数 / 变化率 / END_DATE 数据截止日 (和实时价不是同一时点)	datacenter-web reportName=RPT_HOLDERNUMLATEST	✅ 通 · 户数 257,067 截止 2026-06-30
大宗交易	同步	折溢价与成交额 —— 大额换手的价格与对手方	datacenter-web reportName=RPT_BLOCKTRADE_STA	✅ 通 · 122 笔
全市场季度业绩(基准率底料)	滞后	算「起始 ≥N% 增速四季后仍 ≥50%」的外部视角基准率	efinance get_all_company_performance	✅ 通 · 5566 行
现金流量表(A股 capex)	滞后	购建固定资产支付的现金 —— 面板厂(京东方/TCL)capex 就靠这个	akshare stock_cash_flow_sheet_by_report_em	✅ 通 · 102 行 × 254 列

3b 事件面(缺口)

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
上市公司公告	领先	中标 / 重大合同 / 框架协议 / 订单 —— 对订单驱动的公司(杰瑞、深科达)比财报更直接。 PIT 纪律:只在公告日之后生效	东财 np-anotice-stock	✅ 通 · 5 条
个股资金流	同步	各档(超大/大/中/小)净流入	datacenter-web reportName=RPT_DMSK_TS_STOCKNEW	✅ 通 · 1 日
龙虎榜	同步	游资/机构席位买卖	akshare stock_lhb_detail_em	✅ 通 · 1633 行 × 21 列

4 杠杆与解禁

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
融资融券(深)	同步	融资余额 / 当日买入	akshare stock_margin_detail_szse	✅ 通 · 2101 行 × 8 列
限售解禁	领先	未来解禁日期与市值	akshare stock_restricted_release_detail_em	✅ 通 · 620 行 × 12 列

5 一致预期与评级

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
同花顺盈利预测	领先	分年度净利/EPS 的最小/均值/最大 + 机构数 + 分歧度 —— 三情景的输入	tools/consensus.py	✅ 通 · 3 行 × 6 列
巨潮评级变动	领先	评级调高/调低方向。只覆盖境内券商,外资行的下调看不到	tools/consensus.py	✅ 通 · 877 行 × 11 列
东财研报全文	同步	研报 PDF,可抽产业量价句子	tools/research.py --dig	✅ 通 · 5 篇

6 领先指标·海外需求

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
SEC EDGAR XBRL ⭐	领先	云厂/油服已发生的季度 capex(官方口径)。UA 必须含联系邮箱否则 403	tools/capex.py	✅ 通 · 230 期
Motley Fool 电话会纪要	领先	下期 capex 指引 + 短周期/长周期拆分(SEC 只有总额,拆分只在纪要里)。URL 规律 /earnings/call-transcripts/YYYY/MM/DD/<公司>-<代码>-qN-YYYY-earnings-call-transcript/	requests + 正则取 article-body	✅ 通 · 正文 65,380 字符 · 含 capex
stockanalysis.com 前瞻一致预期	领先	美股分年度营收/EPS 一致预期(免费无 key)	requests + 表格解析	✅ 通 · 有预测表
stockanalysis.com 历史财务	滞后	美股 20 个季度三表(比 SEC XBRL 好解析)	requests	✅ 通 · 有 capex 行
roic.ai	滞后	美股三表(备源)	requests	✅ 通 · 1,366,998B
海外同业电话会纪要	领先	光模块链同业(COHR/LITE/FN/CRDO/MRVL/AVGO/ANET/CIEN)的需求与产能口径。相干 Q4FY26 原话:能见度到 calendar 2028 ,长约到 end of decade	requests + 正则(同 Motley Fool)	✅ 通 · 正文 61,850 字符 · 含 capex

7 领先指标·大宗

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
新浪外盘期货 油价	领先	WTI / 布伦特	tools/commodity.py	✅ 通 · 有报价
北美钻机数(Baker Hughes 转载)	领先	作业量的既成事实 —— 油价和 capex 只是意愿,钻机数是已发生	tools/rigcount.py	✅ 通 · 1,880,339B
人民币中间价(CFETS)	同步	出口占比高的公司的汇兑影响。pageSize ≥ 100 返回 403 是分页超限不是被封	skills/astock-quote/scripts/fx.py	✅ 通 · 20 条

8 宏观

数据源(点名字进官方页)	属性	拿到什么	怎么拿	实测
中美国债收益率	领先	贴现率 —— 高估值成长股的分母	akshare bond_zh_us_rate	✅ 通 · 22 行 × 13 列
全球指数	同步	外围市场温度	akshare index_global_spot_em	❌ FAIL · JSONDecodeError: Expecting value: line 1 column 1 (char

★ = 必需源(缺了做不了基础分析)。本次实测 42 条,通 41 条。

三、本次没通的 1 条

条目	原因	处置
全球指数 index_global_spot_em	走东财 push2 系主机,间歇返回非 JSON	定时抓落库,不要请求时现抓

东财要按主机分开看,不能按域名一刀切:datacenter-web(报表类)本机稳定; push2 / push2his(行情与资金流类)时通时不通。同一个 eastmoney.com 下两种行为。 2026-09-02 把股东户数和个股资金流从 efinance/push2his 改到 datacenter-web 的 RPT_HOLDERNUMLATEST / RPT_DMSK_TS_STOCKNEW 之后,两条都稳定了。

△ 另一类容易误判成「数据源坏了」的:efinance 各接口的参数语义不统一 —— get_latest_holder_number 和 get_all_company_performance 收的是日期不是股票代码。 传错时报的是 time data '300502' does not match format '%Y-%m-%d', 看起来像源出问题,其实是调用方写错。

四、确认拿不到的(附证据日期,别再重复试)

想要	为什么拿不到	证据	影响
北向资金个股净买方向	监管 2024-08-19 起停止日终披露,改按季公布。 不是接口坏了	交易所公告	中。能拿成交额与参与度,拿不到方向。全行业都没有,不是付费能解
海关 HS 85177060 光模块月度出口	海关总署 412(WAF 挡爬虫,真浏览器也过不去);统计局 403;东财宏观 只有进出口总额无 HS 分项	2026-08-31 实测	中低。光模块出口是行业景气的直接量,拿不到只能用同业营收替代
LightCounting 全行业月度出货/现货报价	付费库独有	—	低。研报能给单家公司的量价,给不了全行业序列
审计意见(非标/保留)	免费源无干净接口	a-stock-ai spec 11 实测	中。可用公告关键词代理(「非标/保留意见/问询函/立案/事务所变更」),召回不如付费字段
财报重述追踪(真 PIT)	baostock 给的是重述后的数字配原始 pubDate,重述级前视免费消不掉	a-stock-ai spec 11	中。免费档只能诚实标注为「首次披露口径 PIT」,不是「无未来函数」
外资行(高盛/摩根等)对 A 股的评级与目标价	订阅制,纯 A 股标的无公开转载渠道	2026-09-01 实测富途/雪球/AASocks	高。2026-07-20 高盛把新易盛目标价 841→633(-25%),我们报告同期写「零下调」

上面两条「中」的可以花 ~500 元/年 上 Tushare 5000 积分解决 (fina_audit 审计意见 + ann_date/update_flag 重述追踪)。其余是死局。

五、海外研报:三档渠道,按可靠性排

① 原始材料 —— 应该做主力(免费、稳定、可程序化)

研报里 90% 的信息量本来就来自这些。 与其追二手 PDF,不如直接读高盛读的东西。

拿什么	怎么拿	链接
云厂/同业电话会全文(含下期指引)	Motley Fool,URL 规律 /earnings/call-transcripts/YYYY/MM/DD/<公司>-<代码>-qN-YYYY-earnings-call-transcript/。站内搜索是 JS 的,用外部搜索定位再直取;正文在 class="article-body" 里	微软 FY26Q4
同上,结构化(分 prepared remarks / Q&A)	earningscall API,免费 demo key 可试,覆盖 5000+ 公司、回溯 5 年	earningscall-python
美股前瞻一致预期(分年度营收/EPS)	stockanalysis.com,免费无 key	MSFT forecast
SEC 全部报表(10-K/10-Q/8-K/13F/Form 4)	edgartools,MIT,无 key	dgunning/edgartools
美股 20 季三表(比 XBRL 好解析)	stockanalysis.com / roic.ai	roic.ai

为什么这一档够用:高盛那份新易盛研报里真正驱动结论的东西 ——

1.6T 出货节奏、芯片供给改善、客户 capex —— 全部来自云厂和同业的电话会。

相干 2026-08-19 电话会原话「能见度到 calendar 2028、长约到 end of decade」,这是对 2027-2028 一致预期最硬的需求侧证据,比任何二手摘要都强。

② 中文券商研报 —— 已经有了

tools/research.py --dig 走东财 reportapi + pdf.dfcfw.com,能取全文并抽产业量价句子。GitHub 上同类工具可参考(都是同一批公开接口,取数思路可借鉴):

- [manymore13/report-cli](#) —— 命令行查/下研报,支持 agent 调用
- [lijinglin3/research-report](#) —— 研报下载助手
- [GallenQiu/DeskResearch](#) —— 发现报告等行研站爬虫
- [hugo2046/QuantsPlaybook](#) —— 券商金工研报复现(不是下载,是把研报里的因子实现出来)
- [reportcamp](#) —— 公开渠道汇总的行业报告库(含咨询机构)

③ 外资行研报 PDF 本身 —— 不能当管道

高盛/摩根这类是机构订阅制。手上那份带微信水印的是转手流出的,

不稳定、来源不合规,不能建成自动管道。

可行的做法是把它当外部输入处理:建 private/extern_research/,人工放进去多少就用多少,解析器把预测表、目标价、目标 PE、利益冲突披露抽成结构化 JSON,和自动取的数据分开标注来源。这份高盛报告已经可以当第一个样本 —— 它给的2027E 目标 PE 27.8x = 历史前瞻 PE 均值 28x 就是我们估值锚该用的东西。

六、机器差异与已知的坑

三台机器网络不同,同一条源的可达性不一样。清单必须标明是在哪台机器上测的。

机器	角色	网络
company-linux	源头仓	公司网
mac mini	跑数据的机器	命令行直连深圳电信,Clash 规则分流
MacBook	git 与海外 LLM	TUN 开着走日本节点(本次探测就在这台)

坑(都踩过)

1. macOS 上 python requests 会读系统代理(经 _scproxy 读系统偏好,与环境变量无关),
os.environ.pop 挡不住;curl/git/ssh 则不读。两套行为不同。

2. Clash TUN 模式在 L3 路由层截流,os.environ.pop 是应用层,治不了。

本机能用是因为 Clash 规则里对国内财经域名走了 DIRECT,不是因为那段代码对。 换机器要先在 Clash 规则层放行 +.eastmoney.com、+.sinajs.cn、+.gting.cn、 +.baostock.com、+.iwencai.com,而 Yahoo / SEC / Motley Fool 反而要走代理出海。

3. SEC EDGAR 的 UA 必须含联系邮箱,否则一律 403 —— 云厂 capex 整块废掉。

4. CFETS 中间价 pageSize ≥ 100 返回 403,那是分页超限不是被封。

5. akshare / efinance 内部很多调用不带 timeout,进程级 socket.setdefaulttimeout()
是唯一可靠的兜底,否则会挂死在 CLOSE_WAIT 上。

6. 复权基准要对齐:2026-09-01 拿未复权目标价比未复权日线,中间隔着一送转
(系数 1.40),算出来的隐含涨幅全错。用 query_adjust_factor 换算到同一基准。

七、还缺什么(下一步)

本轮已补上(2026-09-01):

原先列为缺	现在
海外原始材料	✅ yfinance 给 21 只上下游的目标价/分析师预估/评级变动(137~992 条/只);Motley Fool 电话会纪要正文可程序化取
外资口径的一致预期	✅ 两条路:① Yahoo 的 A 股一致预期池含 外资行 (实测新易盛 2026E 营收下沿 544.3 亿正是高盛那份的数);② 巨潮里的外资合资券商(野村东方国际、汇丰前海),fetch_all 会标 _是否外资系
机构调研	✅ 东财 RPT_ORG_SURVEYNEW,含接待家数/形式/时间/接待人
公告	✅ 东财 np-anotice-stock
研报原件	✅ research/ 落列表 + PDF 原件(抽错了能回去核)
外部研报结构化	✅ extern-research-ingest skill
数据时效	✅ 信封里的 fetched_at,digest 每条都显示

还缺(按价值排):

1. **公司季度指引** —— 新易盛在电话会给了 Rmb4.2bn~6.2bn 的季度净利指引,散在公告与调研纪要里,要做关键词抽取
2. **公告正文关键词识别** —— 现在只取到列表。中标/合同/订单对订单驱动的公司比财报更领先
3. **机构调研纪要正文** —— 元数据已通,正文在巨潮的公告 PDF 里,和 research.py --dig 同套路
4. **面板厂 capex** —— 深科达真正的下游。现金流量表接口已通,写个聚合就行
5. **PIT 纪律** —— 每个取数函数加 as_of,按 publish_date <= as_of 切片。没有这个,历史分位和基准率都在偷看未来
6. **高盛/大摩等纯离岸研报** —— 结构上拿不到,走 §五③ 的人工投喂

本文档由 tools/probe_all_sources.py 的实测结果生成,不是手写清单。

表格过期就重跑一次,别凭记忆改。